论文阅读

π0.5：训练配方与泛化

整理异构数据协训练、FAST 与 Flow Matching，以及高层子任务和低层动作的联合建模。

本文目录　7 个章节

Paper Overview

Motivations

Training recipe

Pre-Training

Post-Training (Fine-Tuning)

π0.5 注意力掩码 · 查看原图

「Sonnet Generated」 π 0.5 相对于 π0 的改进

论文原文 · arXiv:2504.16054

Paper Overview

- 背景：想让机器人在非实验室环境执行实际（操作）任务
- 问题（Gap）：VLA在真实开放环境中还没有泛化能力

> "How can we structure a **training recipe** for a robotic learning system that can enable this kind of flexible **generalization**?"

- 贡献：π_0对异构任务进行联合训练来赋予π_0迁移/泛化能力
- 方法：用跨本体、跨任务数据进行混合多模态训练
- 实验：在餐厅和卧室场景测试（并首次展现）π_0对长程（15分钟）灵巧操作的泛化能力（指标：任务进度）

Motivations

范式由专才转向通才：

- 专才(Specialist): 单任务数据→单任务策略

- 通才(Generalist): 多场景/任务数据集→泛化到新场景/任务

VLA复刻VLM范式的局限：

- 理想：Pre-Training(互联网语义知识)→Fine-Tuning(下游操作任务)
- 局限1：缺少系统的Training Recipe来有效整合异构知识源
- 局限2：暴力scaling对复杂长程任务不奏效，线性数据增长无法覆盖指数级场景复杂度
- **Co-Training Recipe**：
- 整合不同构型机器人数据，覆盖不同任务类型，引入非机器人数据（网络图文、语义标注等）
- $\pi_{0.5}$模型架构：区别于传统双模型方案（VLM 规划 + 策略执行），PI 0.5 以单一模型实现CoT式推理

Training recipe

Problem Definition

- Imitation Learning → Next Token Prediction
- Imitation Learning Problem:

$$\max_{\theta} \mathbb{E}_{(\mathbf{a}_{t:t+H}, \mathbf{o}_t, \ell) \sim \mathcal{D}} \log \left(\pi_\theta(\mathbf{a}_{t:t+H} | \mathbf{o}_t, \ell) \right)$$

- Next Token Prediction:

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \ldots, u_{i-1}; \Theta)$$

- 输入输出Token化 → Auto-Regressive Transformer Backbone

Tokenizer的选择

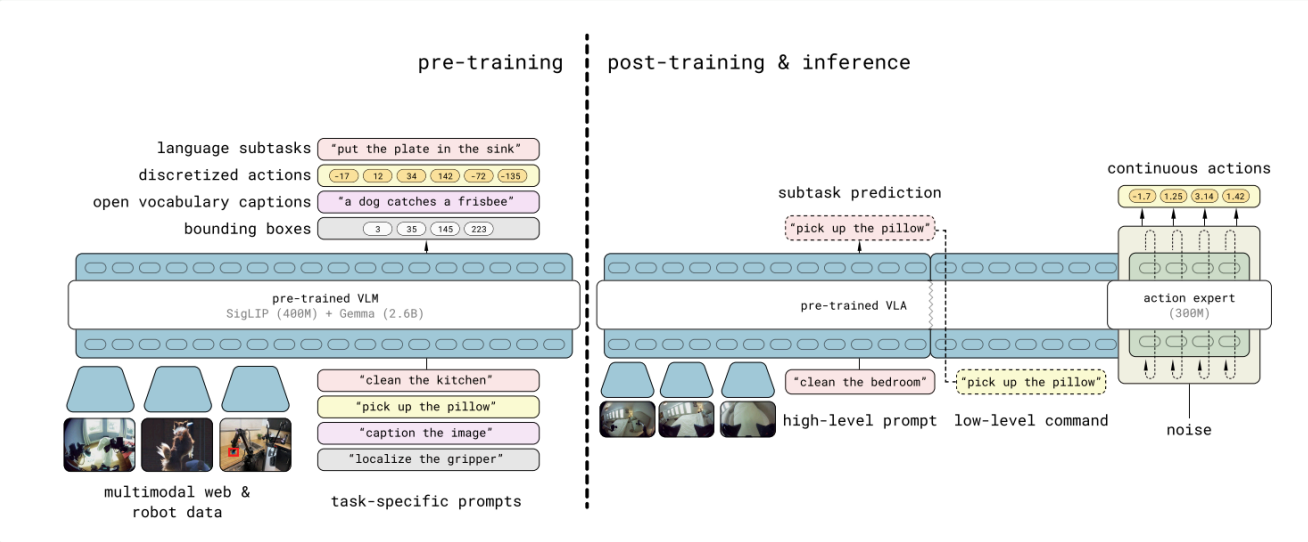
模态	Tokenizer
Image	SigLIP
Text	Gemma
Robot Proprioceptive State	精度截断转文本后用 Gemma
Bounding Box	归一化转为标签 `<locXXXX>` 后用 Gemma
Action (Pre-Training)	FAST-Tokenizer
Action (Fine-Tuning)	Flow Matching + MLP Projection

> bounding box is the specific location of the object, transferred to <locXXXX>

Pre and post Training

> **配图待补**：原笔记中的预训练 / 后训练示意图文件缺失（`Pasted image 20260721142412.png`）。 在 pre-training 部分，high-level subtask 是外部提供的数据

Training Loss



π0.5 预训练、后训练与推理流程 ·

$$\pi_\theta(\mathbf{a}_{t:t+H}, \hat{\ell}|\mathbf{o}_t, \ell) = \pi_\theta(\mathbf{a}_{t:t+H}|\mathbf{o}_t, \hat{\ell})\pi_\theta(\hat{\ell}|\mathbf{o}_t, \ell)$$

- **Action Chunk Prediction**: $\pi_\theta(\mathbf{a}_{t:t+H}|\mathbf{o}_t, \hat{\ell})$
- **High-Level Subtask**: $\pi_\theta(\hat{\ell}|\mathbf{o}_t, \ell)$

$$\mathbb{E}_{\mathcal{D},\tau,\omega}\left[H(x_{1:M}, f_\theta^\ell(\mathbf{o}_t, \ell)) + \alpha \left\|\omega - \mathbf{a}_{t:t+H} - f_\theta^a(\mathbf{a}_{t:t+H}^{\tau,\omega}, \mathbf{o}_t, \ell)\right\|^2\right]$$

- 预训练 $\alpha = 0$，后训练 $\alpha = 10$
- Cross-Entropy Loss of High-Level Text Prediction: $H(x_{1:M}, f_\theta^\ell(\mathbf{o}_t, \ell))$
- Flow Matching Loss of Action Expert: $\left\|\omega - \mathbf{a}_{t:t+H} - f_\theta^a(\mathbf{a}_{t:t+H}^{\tau,\omega}, \mathbf{o}_t, \ell)\right\|^2$

论文原文：

> "$H(x_{1:M}, y_{1:M}^\ell)$ is the cross entropy loss between the text tokens and predicted logits (including the FAST encoded action tokens)"

所以 $x_{1:M}$ 是 ground-truth 离散 token 序列（文本 + FAST 动作 token），$f_\theta^\ell(\mathbf{o}_t, \ell)$ 是 VLM backbone 输出的对应 logits。

Pre-Training

- Training Steps: 280k
- Data Format: all tasks are represented in discrete tokens (actions encoded into discrete tokens via FAST tokenizer)
- Mixture Sampling: all data types are trained simultaneously in a mixed manner

数据类别	缩写	内容描述	比例/规模
移动机械臂数据 (Mobile Manipulators)	MM	在约100个家庭环境中收集的移动机械臂操作数据	约400小时
非移动多环境数据 (non-mobile Multi-Environments)	ME	使用更轻便的(单臂/双臂)机械臂在多种家庭环境中收集的数据	未明确具体小时数，但属于主要机器人数据来源
跨构型实验室数据 (lab Cross-Embodiment)	CE	包含OXE开源数据集（Bridge v2、DROID等）的实验室条件数据	9.1%的预训练混合数据（参考π0的OXE Magic Soup比例）
高层子任务预测数据 (High-Level subtask prediction)	HL	为多阶段任务手动标注语义子任务描述和边界框	来自MM、ME、CE中含多子任务的数据
多模态网络数据 (multi-modal Web Data)	WD	图像描述、视觉问答（VQA）、目标检测等网络数据	未明确具体比例，但用于提供语义和视觉能力

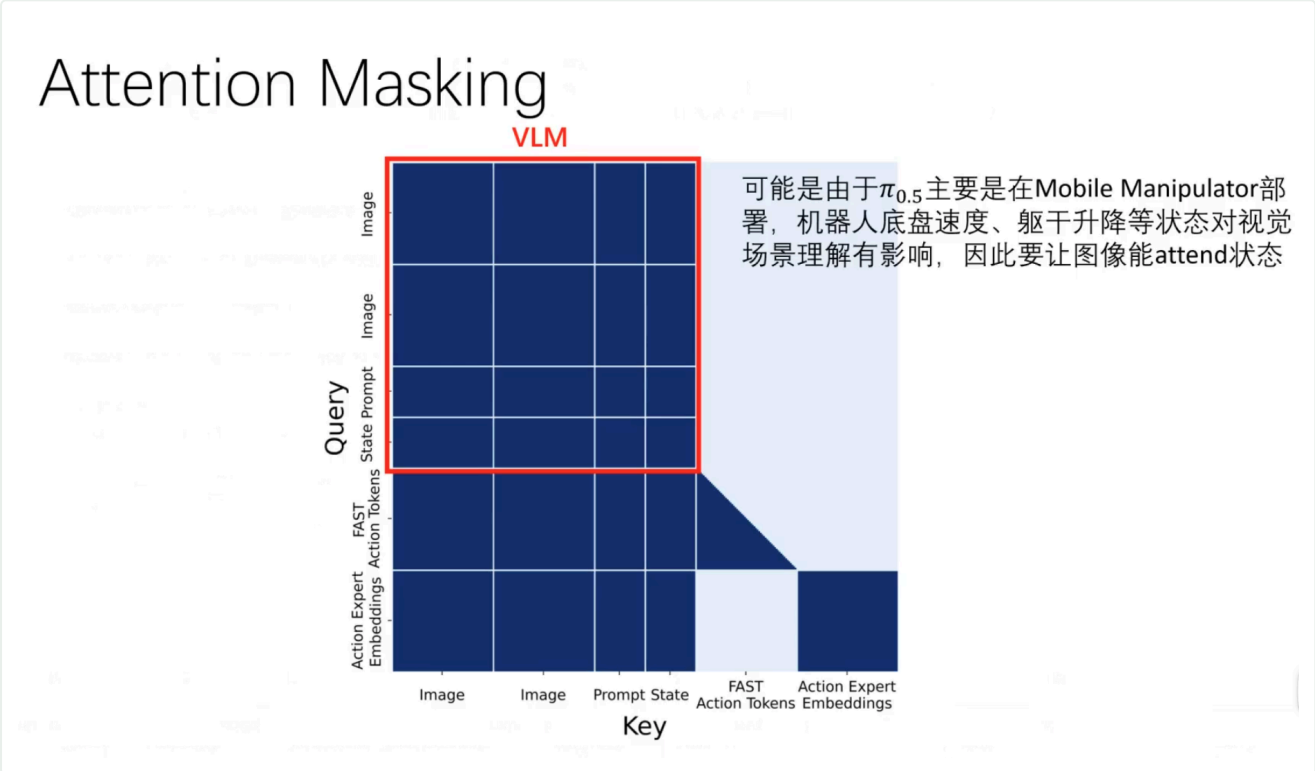
Post-Training (Fine-Tuning)

- Training Steps: 80k
- CE removed
- VI added
- Action Expert using Flow Matching introduced

数据类别	缩写	内容描述	比例/规模
移动机械臂数据 (Mobile Manipulators)	MM	在约100个家庭环境中收集的移动机械臂操作数据	过滤为成功且长度低于阈值的片段
非移动多环境数据 (non-mobile Multi-Environments)	ME	使用更轻便的(单臂/双臂)机械臂在多种家庭环境中收集的数据	过滤为成功且长度低于阈值的片段

数据类别	缩写	内容描述	比例/规模
口头指令 (Verbal Instructions)	VI	由专家用户在机器人执行任务时口述当前应执行的子任务	未披露
高层子任务预测数据 (High-Level subtask prediction)	HL	为多阶段任务手动标注语义子任务描述和边界框	仅保留ME中含多子任务的数据
多模态网络数据 (multi-modal Web Data)	WD	图像描述、视觉问答（VQA）、目标检测等网络数据	维持模型的语义和视觉能力

Data Flow



π0.5 注意力掩码 ·

「Sonnet Generated」 π 0.5 相对于 π0 的改进

1. 离散+连续动作双表示（FAST + Flow Matching 混合训练）

π0 整个训练过程始终使用 flow matching（连续动作，Action Expert）。π0.5 引入了 **FAST tokenizer**（一种基于 DCT 压缩的动作离散化方案），将训练分成两阶段：

预训练阶段（α = 0）：动作用 FAST 离散 token 表示，以标准自回归 next-token prediction 训练，速度快、规模易扩展。

后训练阶段：同时优化两个目标——

$$\mathcal{L} = \mathbb{E}\left[H\left(x_{1:M}, f_\theta^\ell(o_t, \ell)\right) + \alpha \left\|\omega - a_{t:t+H} - f_\theta^a(a_{t:t+H}^{\tau,\omega}, o_t, \ell)\right\|^2\right]$$

其中 $\alpha = 10.0$，两个 action head（FAST token 和 flow matching Action Expert）共存但通过 attention mask 隔离，避免信息泄漏。

实际收益：预训练时用 FAST token 比纯 diffusion 训练计算效率更高；推理时用 flow matching（10 步去噪）获得高精度连续动作。

---

2. 内嵌的层级推理（高层 + 低层统一模型）

π0 中高层规划（VLM）和低层控制（π0）是两个独立模型，靠语言接口串联。

π0.5 将两者**合并为单一模型**，联合建模：

$$\pi_\theta(a_{t:t+H}, \hat{\ell} \mid o_t, \ell) = \pi_\theta(a_{t:t+H} \mid o_t, \hat{\ell}) \cdot \pi_\theta(\hat{\ell} \mid o_t, \ell)$$

推理时的执行顺序：

1. 模型先自回归输出 $\hat{\ell}$（当前子任务，例如 "pick up the plate"）
2. 再以 $\hat{\ell}$ 为条件，flow matching 输出低层动作块

高层推理以 **较低频率**运行（不是每步都重新预测子任务），低层 action chunk 以 50Hz 执行。这类似 chain-of-thought，但专门为机器人控制中的时间异步性设计。

消融实验表明：显式高层推理 > 隐式（仅训练含子任务标注数据但推理时不输出）> 完全没有高层数据，且 π0.5 甚至超过了人类作为 oracle 高层策略的基线。

---

3. 异构数据协训练（Co-training）

π0 的训练数据基本都是机器人动作数据（imitation learning）。π0.5 在数据层面做了根本性扩展，将以下数据源统一进同一个 VLA 序列建模框架：

数据类型	来源	作用
MM：移动机械手	~400h，~100个真实家庭	最直接的目标域数据
ME：多环境非移动臂	轻便单/双臂，更易采集于多家庭	跨本体泛化
CE：实验室跨本体数据	含 OXE，多种机器人类型	多任务技能迁移

数据类型	来源	作用
HL：高层子任务标注	对 MM/ME/CE 数据手工标注子任务	教模型场景语义推理
WD：多模态网络数据	图像字幕（COCO/CapsFusion）、VQA、目标检测（bounding box）	增强 OOD 物体识别和语言理解
VI：语言示范（Verbal Instruction）	人类用语言"遥操作"已训练低层策略来演示子任务序列	提升高层推理策略质量

97.6% 的预训练数据**不来自**移动机械手家务任务，但模型最终能在全新家庭中泛化——这验证了跨域迁移的有效性。消融结果显示去掉 ME 或 CE 都会显著降低性能；去掉 WD 对 OOD 物体语言跟随损害最大。

---

4. 时间步注入方式的细节改动（Action Expert 架构微调）

π0 将 flow matching 时间步 τ 与带噪动作 $a^{\tau,\omega}$ 拼接后一起输入 Action Expert。

π0.5 改为**独立 MLP + adaptive RMSNorm** 的方式注入 τ：

$$\phi(\tau) \xrightarrow{\text{sinusoidal}} \text{swish}(W_2 \cdot \text{swish}(W_1 \cdot \phi(\tau)))$$

然后对 Action Expert 每一层的激活施加 adaptive RMSNorm（类似 DiT 中的 AdaLN），让时间步信息以"调制归一化"方式渗透整个 Action Expert，而非只影响输入层。

---

5. 注意力掩码重新设计

π0 的 Action Expert token 可以全局双向互相 attend。

π0.5 更精细：

- 图像/语言/本体感知构成 prefix，全局双向 attend
- FAST 动作 token 自回归地 attend prefix + 之前的 FAST token
- Action Expert token attend prefix + 彼此，**但不 attend FAST token**（防止两种动作表示之间信息泄漏）
- VLM 的 embedding 不 attend Action Expert（信息单向流动：VLM → Action Expert）

总结对比

维度	π0	π0.5
动作表示	全程 flow matching	预训练用 FAST 离散 token，后训练加 flow matching

维度	π0	π0.5
高层策略	外挂独立 VLM	统一模型内嵌，联合推理
数据来源	机器人演示 + OXE	机器人演示 + 多环境非移动臂 + 网络数据 + 子任务标注 + 语言示范
τ 注入	拼接输入	独立 MLP + adaptive RMSNorm 调制每层
注意力	VLM 因果 + Action Expert 双向	增加 FAST/Expert 隔离掩码，单向信息流
评估场景	实验室 + 已见任务	**全新家庭，完全未见场景**